## Drugi projekat iz Sistema za obradu velike količine podataka

#### Danilo Veljović, 1120

Katedra za računarstvo i informatiku Univerzitet u Nišu, Elektronski fakultet

February 18, 2021

## Sadržaj

1. Cassandra

2. Kafka Producer

3. Kafka Listener

### Opis baze

Cassandra je distribuirana baza podataka koja ispunjava AP uslove, CAP teoreme. Kao takva je pogodna za korišćenje u distribuiranim aplikacijama koje se zahtevaju high availability, ali eventualnu konzistentnost. U ovoj aplikaciji se koristila Cassandra u kojoj je bio kreiran jedan keyspace *citibike*, i jedna tabela *citibike*. Ta tabela ima kolone id, lokaciju, min, max, avg, i message koja predstavlja neku poruku. Na slici na sledećem slajdu je dat deo koda koji služi kao konektor aplikacije na bazu.

#### Cassandra Connector

```
public void connect(String node, Integer port) {
    Cluster.Builder b = Cluster.builder().addContactPoint(node);
public Session getSession() { return this.session; }
public void close() {
public void connect() {
    CassandraConnector client = new CassandraConnector();
```

#### Kafka Producer

Kafka producer će čitati podatke na par sekundi i slati ih na topic. Deo koda koji to ilustruje je dat na slici.

```
while(line != null){
    ProducerRecord<String, String> rec = new ProducerRecord<>(topic, line);
    kafkaProducer.send(rec);

    System.out.println("[PRODUCER] Sent message: " + line);
    //LOGGER.debug("[PRODUCER] Sent message: " + line);
    line = reader.readLine();

    Thread.sleep(millisToSleep);
}
```

Boilerplate deo koda Kafka Listener/Analyzer klase će biti izostavljen (konektovanje na bazu, konektovanje na topic itd). U narednim slajdovima biće samo dat deo koda koji ilustruje različite map-reduce jobove koji se izvršavaju.

Prvi job koji se izvršava jeste testcase job koji samo filtrira sve stanice kojima je odredišna stanica Washington park.Nalazi se zatim min, max i avg vrednost trajanja puta. A onda se za za tako filtriran skup nalazi user type koji je najčešće dolazio na tu stanicu (takođe i min i avg).

```
if (!recordsWhoseEndStationIsWashingtonPark.isEmpty()) {
    Long avg1 = userTypeRDD.map(Tuple2::_2).reduce(SUM_REDUCER) / userTypeRDD.count();
```

Sledeći job koji se izvršava je job koji uzima stanice koje u tom batch koji je pročitan sa topica imaju više od pet polazaka. I za takve podatke se onda nalazi min, max i avg.

Sledeći task koji se izvršava jeste da u tom batchu koji je primljen filtrira one čija je startna lokacija istočno od Lafayette Ave St James Pl. Nalazi se najpopularniji bicikl među takvim podacima (takođe i najmanje popularni bicikl) i srednja vrednost izjamljivanja bicikala.

U jobu na slici ispod se filtriraju svi recordi iz batcha gde je startna stanica južno od Lafayette Ave St James PI. Takođe se i za ove redove uzima dužina putovanja i nalaze najduže, najkraće i prosečna vrednost putovanja.

```
//task 6: number departures from each station at noon where the start station is south of Lafayette Ave & St James PL

JavaRDDcRecord> southOfLafayetteDepartures = rdd_records
    .filter(t -> i.t.getStartStationLatitude().equals(LocalDateFime.RAX))
    .filter(t -> i.t.getStartStationLatitude().compareTo(BigDecimal.valueOf(40.73820660529954)) < 0);

if (isouthOfLafayetteDepartures.isEmpty()) {
    JavaRDDcInteger> tripDurations = southOfLafayetteDepartures.map(Record::getTripDuration);

    Integer mostSouthDepartures = tripDurations.max(Comparator.naturalOrder());

    integer LeastSouthDepartures = tripDurations.sin(Comparator.naturalOrder());

    double avgNumSouthDepartures = tripDurations.rin(Comparator.naturalOrder());

    connector.insertInto(localOrd "South of Lafayette", leastSouthDepartures, mostSouthDepartures, avgNumSouthDep. | message null);
}
```

U nastavku je dato top N kombinacija početna-krajnja stanica, top N startnih lokacija, top N krajnjih lokacija i top N bicikala. Na ovoj slici je dato top N kombinacija početnih i krajnjih stanica.

```
//b. top N start locations and top N end locations and top N bikes

JavaPairRDD<String, Integer> topNLocations = rdd_records
.mapToPair(t -> new Tuple2<>(t.getStartStationName() + " - " + t.getEndStationName(), 1))
.reduceByKey(Integer::sum)
.sortByKey();
List<Tuple2<String, Integer>> listOfLocations = topNLocations.collect();
List<Tuple2<String, Integer>> sortable = new ArrayList<>(listOfLocations);
Comparator<Tuple2<String, Integer>> comparator = (tupleA, tupleB) -> tupleB._2().compareTo(tupleA._2());
sortable.sort(comparator);

for (int i = 0; i < N && !sortable.isEmpty() && sortable.get(i) !=null; i++) {
    connector.insertInto(sortable.get(i)._1, |mmx.null, |max.null, |avgi.null, |message: "Number of occurrences " + sortable.get(i)._2);
}
```

Na ovoj slici je dato top N kombinacija početnih stanica.

Na ovoj slici je dato top N kombinacija krajnih stanica.

Na slici je dat job koji nalazi bicikl koji je najviše puta bio korišćen u tom batchu koji je pročitan iz topica, bicikl koji je najmanje puta iznajmljen iz topica i prosečan broj iznajmljivanja bicikala.

# The End