Prvi projekat iz Sistema za obradu velike količine podataka

Student: Danilo Veljović 1120

Katedra za računarstvo i informatiku Univerzitet u Nišu, Elektronski fakultet

February 18, 2021

Sadržaj

1. Opis dataseta

2. Implementacija

Opis dataseta

Dataset koji je korišćen u izradi aplikacije je Citibike NYC dataset, dat na linku https://www.citibikenyc.com/system-data. Dataset ima prostorno vremenske podatke koji se odnose na jedno iznajmljivanje bicikla.

Podaci koje sadrži su informacije o početnoj stanici (ime, id, vremenske i prostorne koordinate), koliko je trajala vožnja, koji bicikl je iznajmljen, pol, godina rođenja, i subscription service tj koji je tip korisnika koji je vozio itd.

Korišćeni alati

Kod je pisan u programskom jeziku Java (v1.8), korišćen je i Apache Spark framework (v1.6) i Hadoop DFS (v2.6.4).

Na slici je dat testcase. Napisan je jednostavan filter kojim će se izdvojiti samo vožnje čija je krajnja stanica Washington park. Zatim će se za jedan atribut (trip Duration) izračunati prosečna, minimalna i maksimalna vrednost.

```
JavaRDD<Record> recordsWhoseEndStationIsWashingtonPark = rdd_records.filter(t -> t.getEndStationName().eguals(args[0]));
recordsWhoseEndStationIsWashingtonPark.collect().forEach(System.out::println);
JavaRDD<Integer> tripDurationsToWashingtonPark = recordsWhoseEndStationIsWashingtonPark.map(Record::getTripDuration);
Integer min = tripDurationsToWashingtonPark.min(Comparator.naturalOrder());
Integer max = tripDurationsToWashingtonPark.max(Comparator.ngturalOrder()):
```

Figure: Svi polasci čija je krajnja stanica Washington park

Na slici je dat task 1. Napisan je map reduce job koji će samo da beleži polaske sa svake stanice. I zatim se za svaku stanicu broj polazaka upisuje u fajl. Zatim se nalazi stanica sa najviše i najmanje polazaka, kao prosečan broj polazaka sa svake stanice.

```
JavaPairRDD<String, Integer> numberOfDeparturesFromEachStation = rdd_records
        .mapToPair(i -> new Tuple2<>(i.getStartStationName(), 1))
        .reduceBvKev(Integer::sum):
    try {
    } catch (IOException e) {
Integer maxStationAndNumberOfDepartures = numberOfDeparturesFromEachStation.map(t -> t._2).max(Comparator.naturalOrder());
Integer minStationAndNumberOfDepartures = numberOfDeparturesFromEachStation.map(t -> t. 2).min(Comparator.ngturglOrder());
Integer reduce = numberOfDeparturesFromEachStation.map(i -> i, 2).reduce(Integer::sum);
double avoNumOfDeparturesFromEachStations = reduce / (double) numberOfDeparturesFromEachStation.count():
```

Na slici je dat task 2. Napisan je map reduce job koji će samo da beleži pristizanja na svaku stanicu. I zatim se za svaku stanicu broj pristizanja upisuje u fajl. Zatim se nalazi stanica sa najviše i najmanje dolazaka, kao prosečan broj dolazaka sa svake stanice.

```
Integer maxStationAndNumberOfArrivals = numberOfArrivalsToEachStation.map(t \rightarrow t_{-2}).max(Comparator.ngturglOrder());
Integer minStationAndNumberOfArrivals = numberOfArrivalsToEachStation.map(t -> t. 2).min(Comparator.naturalOrder()):
Integer reduced = numberOfDeparturesFromFachStation.man(i \rightarrow i. 2).reduce(Integer::sum):
```

Figure: Svi dolasci na stanicu

```
JavaPairRDD<String. Integer> numberOfDeparturesFromEachStationAtACertainTimeAndForEveryDayOfTheWeek = rdd records
Integer maxNumberOfDeparturesForEachStationAtCertainTimeAndEveryDay =
       numberOfDeparturesFromEachStationAtACertainTimeAndForEveryDayOfTheWeek.map(t -> t. 2).max(Comparator.ngturglOrder()):
       numberOfDeparturesFromEachStationAtACertainTimeAndForEveryDayOfTheWeek.map(t -> t._2).min(Comparator.naturalOrder());
```

Na slici na prethodnom slajdu je dat task 3. U ovom tasku se najpre izvlače svi polasci sa stanica i vreme polaska, izdvajaju se sve stanice čije je vreme polaska u 12, i nalazi se za svaku stanicu koliko je polazaka bilo u 12 časova.

```
.mapToPair(t -> new Tuple2<>(t.getStartStationName() + " " + t.getBikeId(), 1))
Integer mostPopular = mostPopularDayTimeBikesForEachStation.map(t -> t._2).max(Comparator.nαturαlOrder());
Integer leastPopular = mostPopularDayTimeBikesForEachStation.map(t -> t._2).min(Comparator.naturalOrder());
Integer sum = mostPopularDayTimeBikesForEachStation.map(i -> i, 2).reduce(Integer::sum):
```

Na slici na prethodnom slajdu je dat task 4. U ovom delu koda se pronalazi najpopularniji bicikl za svaku stanicu, gde je vreme polaska pre 17:00. Zatim se nalazi minimalna, maksimalna i srednja vrednost za par stanica + bicikl.

Na slici je dat task 5. Ovaj task pronalazi broj polazaka sa svake stanice u podne, gde je stanica polaska istočno od Lafayette Ave St James Pl.

```
.mapToPair(t -> new Tuple2<>(t.getStartStationName(), 1))
Integer mostDepartures = eastOfLafavetteDepartures.map(t -> t._2).max(Comparator.ngturglOrder());
Integer leastDepartures = eastOfLafavetteDepartures.map(t -> t. 2).min(Comparator.ngturglOrder());
Integer sumDep = eastOfLafayetteDepartures.map(i -> i._2).reduce(Integer::sum);
double avgDepartures = sumDep / (double) eastOfLafavetteDepartures.count():
```

Na slici je dat task 6. Ovaj task pronalazi broj polazaka sa svake stanice u podne, gde je stanica polaska južno od Lafayette Ave St James Pl.

```
southOfLafayetteDepartures.collect().forEach(t -> {
Integer mostSouthDepartures = southOfLafavetteDepartures.map(t \rightarrow t. 2).max(Comparator.ngturglOrder())
```

Na slici je dat task 7. Ovaj task pronalazi pol ljudi koji iznajmljuju bicikle leti (jun, jul i avgust) u Washington parku.

```
JavaPairRDD<Integer, Integer> gendersWhoRentBikesInSummer = rdd_records
gendersWhoRentBikesInSummer.foreach(t -> System.out.println()):
gendersWhoRentBikesInSummer.collect().forEach(t -> {
Integer most Genders = south Of Lafayette Departures. map (t -> t_2). max (Comparator. natural Order()):
```

The End