Logistička i softmaks regresija

Samostalna primena i primena u neuronskim mrežama

Student: Danilo Veljović, 1120 Profesor: Dr. Suzana Stojković
Univerzitet u Nišu, Elektronski fakultet
Februar 2021

0 Sadržaj |1

- Uvod
- 2 Teorijske osnove
- 3 Implementacija funkcija i primena u neuronskim mrežama
- 4 Rezultati




1 Outline |2

- 1 Uvod
- 2 Teorijske osnove
- 3 Implementacija funkcija i primena u neuronskim mrežama
- 4 Rezultati

1 Uvod

- Šta je model mašinskog učenja
- Koje su tehnike mašinskog učenja
- Logistička i softmaks regresija



Slika: Slika 1. Uprošćeni šematski prikaz procesa mašinskog učenja

2 Outline |4

- 1 Uvod
- 2 Teorijske osnove
- 3 Implementacija funkcija i primena u neuronskim mrežama
- 4 Rezultati

Elementi modela logističke regresije:

Logistička funkcija -


$$\sigma(\alpha) = \frac{e^{\alpha}}{1 + e^{\alpha}} = \frac{1}{1 + e^{-\alpha}} \tag{1}$$

Funkcija kazne -

$$c(\theta) = [y \ln(\hat{p}) + (1 - y) \ln(1 - \hat{p})]$$
 (2)

- Treniranje modela algoritam opadajućeg gradijenta
- Funkcija predikcije -

$$\hat{y} = \begin{cases} 1, & \hat{\rho} > 0.5 \\ 0, & \hat{\rho} < 0.5 \end{cases}$$
 (3)



Elementi modela softmaks regresije:

Softmaks funkcija -

$$\hat{p}_{k} = \sigma(\mathbf{s(x)})_{k} = \frac{e^{s_{k}(x)}}{\sum_{j=1}^{K} s_{j}(x)}$$
(4)

Funkcija kazne -

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^{m} \sum_{k=1}^{K} y_{k}^{(i)} ln(\hat{\rho}_{k}^{(i)})$$
 (5)

- ► Treniranje modela algoritam opadajućeg gradijenta
- Funkcija predikcije argument koji daje maksimalnu vrednost softmaks funkcije



3 Outline 17

- 1 Uvod
- 2 Teorijske osnove
- 3 Implementacija funkcija i primena u neuronskim mrežama
- 4 Rezultati

```
In [119]: import matplotlib.pvplot as plt
             plt.figure(figsize=(10, 6))
             plt.scatter(X[y == 0][:, 0], X[y == 0][:, 1], color='b', label='0')
             plt.scatter(X[y == 1][:, 0], X[y == 1][:, 1], color='r', label='1')
plt.scatter(X[y == 2][:, 0], X[y == 2][:, 1], color='g', label='2')
             plt.legend();
               4.5
               4.0
               3.5
               3.0
              2.5
               2.0
                           4.5
                                       5.0
                                                   5.5
                                                                6.0
                                                                            6.5
                                                                                        7.0
                                                                                                                 8.0
```

Slika: Linearno separabilne klase/vrste perunike



```
class LogisticRegression:
    def __init__(self, lr = 0.01, num_iter = 10000, fit_intercept = True, verbose = False):
        self.lr = lr
        self.num_inter = num_iter
        self.fit_intercept = fit_intercept
        self.verbose = verbose
```

Slika: Konstruktor modela logističke regresije

```
def __sigmoid(self, z):
    return 1/(1 + np.exp(-z))

def __loss(self, h, y):
    return(-y * np.log(h) - (1 - y) * np.log(1 - h)).mean()
```

Slika: Logistička funkcija i funkcija gubitaka



```
def fit(self, x, y):
    if(self.fit_intercept):
        x = self.__add_intercept(X)

self.theta = np.zeros(X.shape[1])

for i in range(self.num_inter):
    z = np.dot(X, self.theta)
    h = self.__sigmoid(z)
    gradient = np.dot(X, T, (h - y)) / y.size
    self.theta -= self.lr *gradient

if(self.verbose -= True and i % 10000 == 0):
    z = np.dot(X, self.theta)
    h = self.__isigmoid(z)
    print(f'loss(self.theta)
    h = self.__isigmoid(z)
    print(f'loss(self.theta)
```

Slika: Funckija za treniranje modela

```
def predict_prob(self, X):
    if self.fit_intercept:
        X = self.__add_intercept(X)
    return self.__sigmoid(np.dot(X, self.theta))

def predict(self, X):
    return self.predict_prob(X).round()
```

Slika: Funkcija za predikciju



```
class SoftmaxRegression:
    def __init__(self, K, lr=0.01, num_iter=10000):
        self.lr = lr
        self.num_iter = num_iter
        self.K = K
```

Slika: Konstruktor modela softmaks regresije

```
def __softmax(self, z):
   z = np.max(z)
   return np.exp(z) / np.sum(np.exp(z))
def h(self, X, y):
   return self. softmax(X @ self.theta)
def J(self, preds, y, m):
   return np.sum(- np.log(preds[np.arange(m), v]))
def T(self, y, K):
   # one hot encoding
   one hot = np.zeros((len(v), K))
   one hot[np.arange(len(y)), y] = 1
   return one hot
def compute gradient(self, theta, X, y, m):
   preds = self. h(X, theta)
   gradient = 1 / m * X.T @ (preds - self. T(y, self.K))
   return gradient
```

Slika: Softmaks funkcija i funkcija gubayayını у Нишу ЕЛЕКТРОНСКИ ФАКУЛТЕТ

```
def fit(self, X, y):
   hist = {'loss': [], 'acc': []}
   m, n = \hat{X}.shape
   np.random.seed(0)
   self.theta = np.random.random((n, self.K))
   for i in range(self.num iter):
       gradient = self.__compute_gradient(self.theta, X, y, m)
       self.theta -= self.lr * gradient
       # Loss
       preds = self, h(X, self,theta)
       loss = self.__J(preds, y, m)
       for j in range(len(y)):
           if np.argmax(self._h(X[j], self.theta)) == y[j]:
               c += 1
           acc = c / len(y)
           hist['acc'].append(acc)
       # print stats
       if i % 5000 == 0:
           print('{:.2f} {:.2f}%'.format(loss, acc * 100))
```

Slika: Funckija za treniranje modela

```
def predict_prob(self, X):
    return self.__softmax(np.dot(X, self.theta))

def predict(self, X):
    return np.argmax(self.predict_prob(X), axis=1)
```

Slika: Funkcija za predikciju



3 Korišćenje logističke funkcije kao funkcije aktivacije u NN

```
# build the neural network
model = keras.models.Sequential()
model.add(keras.layers.Flatten(input_shape=[28, 28]))
model.add(keras.layers.Dense(380, activation=keras.activations.relu))
model.add(keras.layers.Dense(100, activation=keras.activations.relu))
model.add(keras.layers.Dense(1, activation=keras.activations.sigmoid))
```

Slika: Isečak koda za kreiranje modela

Slika: Isečak koda za treniranje

```
X_new = X_test[:3]

y_proba = model.predict(X_new) > 0.5

print(y_proba)

print(y_test[:3])

Универзитет у Нишу

ЕЛЕКТРОНСКИ ФАКУЛТЕТ
```

3 Korišćenje softmaks funkcije kao funkcije aktivacije u NN

```
# build the neural network

model = keras.models.Sequential()

model.add(keras.layers.Flatten(input_shape=[28, 28]))

model.add(keras.layers.Dense(308, activation=keras.activations.relu))

model.add(keras.layers.Dense(108, activation=keras.activations.relu))

model.add(keras.layers.Dense(10, activation=keras.activations.softmax))
```

Slika: Isečak koda za kreiranje modela

Slika: Isečak koda za treniranje

```
X_new = X_test[:3]
y_proba = model.predict(X_new)
print(y_proba.round(2))
print(y_test[:3])
```



4 Outline 15


- 1 Uvod
- 2 Teorijske osnove
- 3 Implementacija funkcija i primena u neuronskim mrežama
- 4 Rezultati

4 Rezultati primene logističke regresije

```
In [36]: from sklearn.metrics import confusion_matrix
    confusion_matrix(ret, rety)

Out[36]: array([[49, 8],
    [1, 58]], dtype=int64)
```

Slika: Matrica konfuzije



Slika: ROC kriva

```
In [46]: from sklearn.metrics import roc_auc_score roc_auc_score(rety, ret)
Out[46]: 0.99
```

Slika: Površina ispod krive





Slika: Metrike

Slika: Testiranje modela nad test podacima



```
In [142]: from sklearn.metrics import confusion matrix
          confusion matrix(ret. retv)
Out[142]: array([[50, 0, 0],
                 [0, 28, 2],
                 [ 0, 22, 38]], dtype=int64)
In [157]: from sklearn.metrics import precision recall facore support as score
          precision, recall, fscore, support = score(rety, ret)
          print('precision: {}'.format(precision))
          print('recall: {}'.format(recall))
          print('fscore: {}'.format(fscore))
          print('support: {}'.format(support))
          precision: [1.
                                0.93333333 0.633333331
          recall: [1. 0.56 0.95]
          fscore: [1, 0,7 0,76]
          support: [50 50 40]
```

Slika: Matrica konfuzije i metrike

Slika: Testiranje modela nad test podacima



```
[[47192 4449]
[ 2301 1058]]
```

Slika: Matrica konfuzije

```
precision: [0.91384752 0.31497469]
recall: [0.95350858 0.19211912]
fscore: [0.93325687 0.23866456]
```

Slika: Metrike

```
[[0.8780212]
[0. ]
[0. ]]
[9 2 1]
```

```
[[5237] 22 193 344 19 0 849 0 15 0]

[5 5379] 1.35 6 6 6 0 3 0]

[42 2 4580 32 289 1 316 0 5 0]

[38 41 32 590 4 91 0 78 0 8 0 0]

[14 8 582 222 4995 6 477 0 22 0]

[1 0 0 0 0 8547 5 0 6 47] 0 10 0]

[10 0 0 0 0 8547 5 0 6 47]

[10 0 0 0 0 65 0376 3 0 10 0]

[10 0 0 0 0 65 0376 3 0 10 0]

[10 0 0 0 0 65 0376 3 0 10 0]

[10 0 0 0 0 65 0376 3 0 10 0]

[10 0 0 0 0 65 0376 3 0 10 0]

[10 0 0 0 10 10 3 0 0 13 1 35360]

[10 0 0 0 1 0 3 0 13 1 35360]
```

Slika: Matrica konfuzije

```
precision: [0.8204200 0.9896441 0.8054522 0.94201887 0.79122446 0.98675136 0.8055627 0.94201887 0.79122446 0.98675136 0.805562 0.83533333 0.9998345 0.9820444 0.98728891 0.83533333 0.9998345 0.9820444 0.98728891 0.8353333 0.9998345 0.9820444 0.98728891 factor: [0.87465938 0.98867265 0.8353353 0.9998345 0.9820343 0.98728096 0.8353135 0.99762096 0.9853135 0.99762096 0.97553180 0.8446783 0.98762096 0.97553180 0.98445716 0.985045316 0.97762096
```

Slika: Metrike

```
[[0. 0. 0. 0. 0. 0. 0. 0. 0. 1.]

[0. 0. 1. 0. 0. 0. 0. 0. 0. 0.]

[0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]]

[9 2 1]
```

Slika: Rezultati primene nad test pod